



PENINGKATAN PERFORMA KLASIFIKASI MELANOMA BERBASIS ENSEMBLE TRANSFER LEARNING MENGGUNAKAN BAYESIAN OPTIMIZATION DENGAN TREE-STRUCTURED PARZEN ESTIMATOR

Melanoma Classification via Ensemble Transfer Learning with Tree-structured Parzen Estimator (TPE)

DENSENET-121

INCEPTIONV3

XCEPTION

VIT-SMALL/16

BAYESIAN OPTIMIZATION · TPE · OPTUNA

Penelitian ini mengimplementasikan klasifikasi biner lesi kulit melanoma (**Benign vs. Malignant**) menggunakan empat arsitektur pra-latih — **DenseNet-121**, **InceptionV3**, **Xception**, dan **Vision Transformer (ViT-Small/16)** — yang masing-masing di-fine-tune secara independen dengan hyperparameter yang dicari otomatis via **Bayesian Optimisation (TPE)** melalui **Optuna** (10 HP per model, 15–30 trial). Output probabilitas keempat model kemudian difusikan melalui **weighted ensemble** dengan bobot yang ditemukan oleh pencarian TPE sekunder menggunakan objektif komposit **OBJ-16** ($0.7 \times \text{AUC} + 0.1 \times \text{Recall} + 0.1 \times \text{Precision} + 0.1 \times \text{Accuracy}$) yang dipilih dari perbandingan sistematis 20 formulasi kandidat (10.000 total trial). Generalisasi dievaluasi pada test set eksternal independen (**DS2, Mendeley**) yang tidak pernah digunakan selama pelatihan.


METODOLOGI

PIPELINE KESELURUHAN


DATA PREPARATION



DATA SPLITTING



MODEL ENSEMBLE (CNN + ViT)



ARSITEKTUR

- DenseNet-121
- InceptionV3
- Xception
- ViT-Small/16

SEARCH SPACE (10 HP / MODEL)

Parameter	CNN Range	ViT Variasi
lr	log-uniform	log-uniform
optimizer	Adam/AdamW/Adamax	AdamW (fixed)
batch_size	{32, 64}	{32, 64}
dropout	uniform	uniform
unfreeze_init	last / last_2_blocks	last / last_2_blocks
use_focal	{True, False}	{True, False}
layer_decay	—	[0.65, 0.95] (LLRD)
warmup_epochs	—	[2, 6]

CNN: 30 trial · 12 epoch/trial · early stop (patience=3)
ViT: 15 trial · 8 epoch/trial · n_startup_trials=8

PROGRESSIVE UNFREEZE SCHEDULE (CNN 35 EPOCH)

Epoch	Strategi	LR Scale
1 – 4	Frozen backbone	1.00×
5 – 9	last_block	0.20×
10 – 17	last_2_blocks	0.08×
18 – 35	Full fine-tune	0.02×

Head LR = 5× backbone · ViT: LLRD λ=0.8005

DATASET

	DS1 (Train)	DS2 (Ext. Test)
Sumber	Kaggle / Bhavesh	Kaggle / Hasnain
Train	11.879 img	9.605 img
Test	2.000 img	1.000 img
Resolusi	224×224 px	300×300 px
Peran	Primary eval	Ext. generalisation

Class imbalance: `WeightedRandomSampler` — bobot $1/\sqrt{n_c}$

HASIL — SCENARIO I (MODEL INDIVIDUAL)

DS1 test set, TTA ×10. Dibandingkan dengan paper acuan Sanateş & Özbay (2025).

Model	Acc	Prec	Recall	F1	AUC	Paper Acc	Δ Acc
DenseNet-121	95.20%	95.02%	95.40%	95.21%	0.9874	94.50%	+0.70%
InceptionV3	95.35%	96.51%	94.10%	95.29%	0.9894	91.20%	+4.15%
Xception	93.80%	94.97%	92.50%	93.72%	0.9850	93.80%	±0.00%
ViT-Small/16	95.10%	96.98%	93.10%	95.00%	0.9898	88.25%	+6.85%

KERANGKA ENSEMBLE — WEIGHTED AVERAGE FUSION



HASIL — SCENARIO II (WEIGHTED ENSEMBLE)

96.20% ACCURACY	96.57% PRECISION	95.80% RECALL	
96.18% F1-SCORE	0.9942 AUC-ROC		
Metode	Acc	AUC	F1
Sarıtaş & Özbay (2025)	95.25%	0.990	95.20%
Ensemble (this work)	96.20%	0.9942	96.18%
Δ	+0.95%	+0.0042	+0.98%

BOBOT ENSEMBLE OPTIMAL (TPE 100 TRIAL, OBJ-16)

ViT-Small/16	33.42%
InceptionV3	25.75%
Xception	20.68%
DenseNet-121	20.15%

Best OBJ-16 score pada validation set: **0.9689** · ViT menerima bobot terbesar (=33%), konsisten dengan individual AUC tertinggi.

HASIL — SCENARIO III (CROSS-DATASET DS2)

97.50%

ACCURACY

97.98%

PRECISION

97.00%

RECALL

97.49%

F1-SCORE

0.9965

AUC-ROC

Model	DS1 Acc	DS2 Acc	Δ	DS2 Recall
DenseNet-121	95.20%	97.00%	+1.80%	97.60%
InceptionV3	95.35%	97.60%	+2.25%	97.00%
Xception	93.80%	95.30%	+1.50%	94.20%
ViT-Small	95.10%	97.10%	+2.00%	96.60%
Ensemble	96.20%	97.50%	+1.30%	97.00%

Semua model tidak mengalami degradasi saat dievaluasi pada DS2. Ensemble yang hanya dilatih pada DS1 mengungguli EfficientNet-B0 yang dilatih penuh pada DS2 (Sabir & Mehmood, 2024: Acc 97.00%, AUC 0.9900) dalam akurasi, presisi, F1, dan AUC — tanpa retraining apapun.

HYPERPARAMETER OPTIMAL (TPE)

CNN MODELS

All three CNN models share the same 10-parameter search space.

Hyperparameter	DenseNet-121	InceptionV3	Xception
Learning rate	9.03×10^{-3}	3.33×10^{-3}	4.33×10^{-4}
Optimizer	Adamax	AdamW	Adam
Unfreeze init	last_2_blocks	last_2_blocks	last_block
Batch size	64	64	32
Dropout	0.2578	0.3943	0.4296
Weight decay	1.45×10^{-4}	8.14×10^{-6}	2.94×10^{-6}
Focal loss	No	No	No
Focal γ	1.7022	1.2905	2.1649
Label smoothing	0.0284	0.1136	0.0555
LR scheduler	OneCycle	Cosine	OneCycle
Best val acc	0.9220	0.9091	0.9091

VIT-SMALL/16

Hyperparameter	Value
Learning rate	3.67×10^{-4}
Optimizer	AdamW
Batch size	32
Dropout	0.1155
Weight decay	1.44×10^{-3}
Layer decay	0.8005
Unfreeze init	last_block
Focal loss	Yes (γ=1.2373)
Label smoothing	0.0807
Warmup epochs	4
Best val acc	0.9310

FANOVA — HYPERPARAMETER IMPORTANCE (TOP 5 PER MODEL)

PERBANDINGAN HYPERPARAMETER PALING BERPENGARUH PADA SETIAP MODEL

DENSENET-121			INCEPTIONV3		
#	Hyperparameter	Score	#	Hyperparameter	Score
1	lr	0.6227	1	lr	0.2812
2	use_focal	0.1081	2	weight_decay	0.1714
3	weight_decay	0.0991	3	focal_gamma	0.1666
4	focal_gamma	0.0368	4	dropout	0.1356
5	dropout	0.0336	5	label_smoothing	0.1093

XCEPTION			VIT-SMALL/16		
#	Hyperparameter	Score	#	Hyperparameter	Score
1	dropout	0.2710	1	unfreeze_init	0.4508
2	focal_gamma	0.2270	2	lr	0.1776
3	label_smoothing	0.2190	3	layer_decay	0.1661
4	lr	0.1510	4	focal_gamma	0.0780
5	weight_decay	0.0590	5	warmup_epochs	0.0449

Insight utama: DenseNet-121 sangat didominasi `learning_rate` (62%), sedangkan ViT-Small/16 paling sensitif terhadap `unfreeze_init` (45%). Strategi fine-tuning ViT berbeda fundamental dengan CNN.

PEMILIHAN OBJECTIVE FUNCTION

20 formulasi × 500 trial TPE = **10.000 total trial**. OBJ-16 terpilih karena satu-satunya yang mencapai nilai tertinggi secara simultan pada tiga sumbu evaluasi.

ID	Formula	DS1 AUC	DS2 Acc	DS2 Rec
OBJ-01	$1.0 \times \text{Recall}$	0.9941	0.9740	0.9700
OBJ-02	$1.0 \times \text{AUC}$	0.9939	0.9750	0.9700
OBJ-15	$0.7 \times \text{AUC} + 0.1 \times \text{R} + 0.1 \times \text{F1} + 0.1 \times \text{Acc}$	0.9942	0.9740	0.9700
OBJ-16★	$0.7 \times \text{AUC} + 0.1 \times \text{R} + 0.1 \times \text{P} + 0.1 \times \text{Acc}$	0.9943	0.9750	0.9720
OBJ-17	$0.7 \times \text{AUC} + 0.1 \times \text{R} + 0.1 \times \text{P} + 0.1 \times \text{F1}$	0.9942	0.9750	0.9720

OBJ-16 unik karena DS2 Accuracy 0.975, DS2 Recall 0.972, dan DS1 AUC 0.9943 — tertinggi di antara semua 20 formulasi.

CONFUSION MATRIX — RINGKASAN DS1 & DS2

DS1 TEST SET (2.000 GAMBAR PER KELAS)

Model	TP	FP	FN	TN
DenseNet-121	954	50	46	950
InceptionV3	941	34	59	966
Xception	925	49	75	951
ViT-Small/16	931	29	69	971

DS2 MENDELEY (1.000 GAMBAR PER KELAS)

Model	TP	FP	FN	TN
DenseNet-121	488	18	12	482
InceptionV3	485	9	15	491
Xception	471	18	29	482
ViT-Small/16	483	12	17	488

KESIMPULAN

Pendekatan TPE otomatis berhasil menemukan konfigurasi hyperparameter yang lebih baik dibanding paper acuan pada semua model. ViT-Small/16 menunjukkan peningkatan terbesar (Δ Acc +6.85% vs Sanateş & Özbay, 2025), mengkonfirmasi manfaat pencarian bayesian pada arsitektur Transformer yang sensitif terhadap strategi fine-tuning.

Weighted ensemble dengan bobot optimal dari TPE (OBJ-16) secara konsisten mengungguli seluruh model individual, mencapai AUC 0.9942 pada DS1. Generalisasi lintas-dataset menunjukkan peningkatan di semua model (DS2 Acc Ensemble: **97.50%**) tanpa retraining, membuktikan robustness representasi yang dipelajari.

fANOVA importance mengungkap perbedaan mendasar antara CNN dan ViT: pada CNN, learning rate mendominasi (DenseNet 62%), sedangkan pada ViT, strategi unfreezing menjadi faktor terpenting (45%). Temuan ini dapat digunakan sebagai panduan efisiensi komputasi untuk pencarian hyperparameter di masa depan.